

Predicción diabetes tipo 2 a partir de un cuestionario telefónico

15 de junio de 2026

Resumen

La diabetes mellitus tipo 2 (DM2) es una enfermedad crónica de gran difusión cuyo diagnóstico tardío aumenta las complicaciones y costes sanitarios.

Los métodos clínicos tradicionales de cribado pueden resultar costosos o poco accesibles para la población general. El objetivo de este trabajo es diseñar un modelo predictivo que permitan identificar de manera temprana el riesgo de DM2 a partir de datos obtenidos mediante encuestas telefónicas de salud pública, concretamente el conjunto de datos BRFSS 2014 del CDC (EEUU). El proyecto emplea una metodología basada en el proceso de minería de datos y aprendizaje automático. Tras limpiar el conjunto de datos original, se transformaron, se realizó la reducción de la dimensionalidad del conjunto de datos mediante Recursive Feature Elimination (RFE) permitiendo la selección de las variables más predictivas, se equilibró la variable objetivo mediante técnicas de over-sampling (SMOTENC) para corregir el desequilibrio de clases. Después se mitigó el sesgo por edad. A continuación se entrenó un modelo de clasificación binaria supervisada (Regresión Logística). Al modelo se le aplicó SHAP, método para explicar las predicciones del mismo. Finalmente se integró el modelo en una aplicación con interfaz gráfica.

Como conclusión, el riesgo de diabetes depende tanto de parámetros clínicos como de hábitos de vida, acceso a la atención médica y factores demográficos.

Abstract

Type 2 diabetes mellitus (T2DM) is a widespread chronic disease whose delayed diagnosis increases complications and healthcare costs.

Traditional clinical screening methods can be expensive or inaccessible to the general population. The aim of this work is to design a predictive model that allows for the early identification of T2DM risk using data obtained through public health telephone surveys, specifically the 2014 BRFSS dataset from the CDC (USA). The project employs a methodology based on data mining and machine learning. After cleaning the original dataset, it was transformed, and dimensionality reduction was performed using Recursive Feature Elimination (RFE), allowing the selection of the most predictive variables. The target variable was balanced using oversampling techniques (SMOTENC) to correct class imbalance. Finally, age bias was mitigated. A supervised binary classification model (Logistic Regression) was then trained. The SHAP method, used to explain the model's predictions, was applied to the model. Finally, the model was integrated into an application with a graphical interface.

In conclusion, the risk of diabetes depends on clinical parameters, lifestyle habits, access to healthcare, and demographic factors.

Índice general

1. Introducción	7
1.1. Contexto y justificación del Trabajo	7
1.2. Objetivos del Trabajo	9
1.3. Impacto en sostenibilidad, ético-social y de diversidad	10
1.4. Enfoque y método seguido	11
1.5. Breve resumen de productos obtenidos	11
1.6. Breve descripción de los otros capítulos de la memoria	12
2. Materiales y métodos	14
2.1. Fuentes de datos utilizadas	14
2.2. Herramientas tecnológicas	14
2.3. Uso combinado de Copilot y O'Reilly en el notebook	15
2.4. Procesamiento de datos	16
2.4.1. Limpiar el conjunto de datos	16
2.4.2. Transformación de los datos	19
2.4.3. Seleccionar las variables más predictivas	19
2.4.4. Balanceo con SMOTENC	20
2.4.5. Mitigación de sesgos con AIF360	22

2.4.6. Entrenar el modelo	23
2.4.7. Cómo se entrena y valida Regresión Logística	24
2.4.8. Evaluar el desempeño de los modelos	25
2.4.9. SHAP	27
2.5. Análisis de riesgos	29
3. Resultados	31
3.1. Procesamiento de datos	31
3.1.1. Reducción de variables	31
3.1.2. Balancear la variable objetivo	34
3.1.3. Mitigación de sesgos con AIF360	34
3.1.4. Modelo de Regresión Logística	36
3.1.5. Explicabilidad con SHAP	37
4. Conclusiones y trabajos futuros	39
5. Glosario	41
6. Bibliografía	43
7. Anexos	48

Índice de figuras

2.1. Diagrama de flujo de las etapas de creación de modelos y su evaluación	17
2.2. Conjunto de datos desbalanceado para DIABETE3	18
2.3. Valores en la variable DIABETE3 del juego de datos original .	18
2.4. Variable edad (_AGEG5YR)	19
3.1. Gráfica con las variables más explicativas y su grado de im- portancia	32

Variable	Descripción
_STSTR	Estrato de murstreo.
WTKG3	Peso en kilogramos.
CTELENUM	Número de teléfonos en el hogar.
ASBIDRNK	Consumo de bebidas alcohólicas.
ASBIRDUC	Consumo de bebidas dietéticas.
WTCHSALT	Evita la sal en las comidas.
CSRVSUM	Realiza servicio comunitario.
CSRVPAIN	Realiza servicio para personas con dolor.
SCNTMEL1	Frecuencia de sentirse solo.
SCNTPAID	Frecuencia de estrés por problemas monetarios.
SCNTLPAD	Frecuencia de extresarse por salir tarde.
SCNTVOT1	Participación en votaciones.
CTELNUM1	Uso del teléfono celular.
_RFHLTH	Estado general de salud percibida.
RACEG21	Categoría racial / étnica.
_AGE_G	Grupo de edad.
_BMI5CAT	Categoría de IMC (Índice de Masa Corporal).

3.2.	33
3.3. Antes y después de la mitigación	36
3.4. Diagrama SHAP con Regresión Logística	38

7.1. Aplicación de predicción con interfaz gráfica	49
--	----

Índice de cuadros

1.1. Tabla DAFO	12
2.1. Matriz de confusión	26
3.1. Las variables más explicativas según RFE	31
3.2. Sesgo según edad	34
3.3. Interpretación métrica Disparate Impact de AIF360	35

Métrica	Valor	Interpretación
Fold	3	Promedio sobre 3 validaciones cruzadas: estabilidad moderada.
Accuracy	0.706	El modelo acierta en ~70 % de los casos; correcto para datos reales y desbalanceados.
Precision	0.698	De los casos predichos como "diabetes", ~70 % son verdaderos positivos.
Recall	0.726	El modelo detecta ~73 % de los casos reales de diabetes; buen nivel de sensibilidad para cribado.
F1	0.712	Equilibrio entre precisión y recall; indica rendimiento balanceado.
ROC_AUC	0.781	Capacidad discriminativa buena: el modelo separa correctamente positivos y negativos en ~78 % de las veces.

3.4.	37
------	----

Capítulo 1

Introducción

1.1. Contexto y justificación del Trabajo

El ámbito del trabajo final será el de la salud. Un proyecto donde se diseña e implementa un sistema de detección precoz de una enfermedad: la diabetes tipo 2.

Este proyecto tiene un impacto social positivo y es una contribución al ámbito de la salud pública. El objetivo es crear un modelo de clasificación preciso a partir de datos obtenidos de forma legal y transparente mediante encuestas telefónicas oficiales, lo que facilitaría un cribado preventivo más asequible y temprano para los pacientes, reduciendo costes en el sistema de salud comparado con análisis clínicos de laboratorio.

La diabetes tipo 2 (DM2) es un estado en el que la insulina producida no puede mantener estable el nivel de glucosa en sangre en todo el cuerpo, y se presenta con mayor frecuencia en personas mayores de 40 años. El tipo más común de diabetes es la DM2, que representa entre el 90 y el 95 % de todos

los casos de diabetes diagnosticados en todo el mundo. (Ashisha, 2024)

Además es una enfermedad crónica de gran difusión cuyo diagnóstico tardío aumenta complicaciones y costes sanitarios. Los métodos clínicos tradicionales de cribado pueden resultar costosos o poco accesibles para la población general. El objetivo de este trabajo es diseñar modelos predictivos que permitan identificar de manera temprana el riesgo de DM2 a partir de datos obtenidos mediante encuestas telefónicas de salud pública, concretamente el conjunto de datos BRFSS 2014 del CDC.

El BRFSS es una herramienta epidemiológica diseñada para medir la distribución y los determinantes de los principales factores de riesgo de enfermedades crónicas en la población adulta de Estados Unidos. Su estructura, basada en variables demográficas, conductuales, clínicas y sociales, permite aplicar principios epidemiológicos clásicos —como el análisis de distribución, determinantes y prevalencia— al estudio de la diabetes tipo 2. En este trabajo, estos conceptos se integran en un enfoque de aprendizaje automático (Moccia, 2024), donde los modelos predictivos utilizan precisamente los factores epidemiológicos identificados en la literatura (edad, IMC, comorbilidades, determinantes sociales) para estimar el riesgo de diabetes tipo 2. La interpretabilidad mediante SHAP permite traducir los resultados del modelo a un lenguaje epidemiológico, reforzando la relación entre la teoría epidemiológica y la predicción por ordenador.

1.2. Objetivos del Trabajo

I. **Objetivos generales:** Diseñar e implementar un modelo predictivo para identificar el riesgo de diabetes tipo 2 basado en datos del BRFSS.

II. **Objetivos específicos:**

- Limpiar el conjunto de datos del BRFSS eliminando filas y columnas innecesarias y validando la integridad de los registros (CDC, 2014).
- Imputar los valores faltantes utilizando el algoritmo SimpleImputer de sklearn.
- Seleccionar las variables más predictivas mediante Recursive Feature Elimination (Scikit-learn (s.f.)).
- Balancear la variable objetivo mediante técnicas de over-sampling adaptadas al desequilibrio de clases (Lemaître:n.d.).
- Mitigación de sesgos mediante AIF360.
- Entrenar y optimizar un algoritmo de aprendizaje automático binario supervisado (UOC Labs).
- Evaluar el desempeño del modelos con métricas de precisión, sensibilidad, especificidad y AUC-ROC (Saito y Rehmsmeier: 2015).
- Aplicar SHAP para interpretabilidad. (Allani, 2025; Awan, 2024)
- Integrar el modelo seleccionado en una aplicación GUI desarrollada en Python/Tkinter para generar predicciones individuales (Ramírez: 2022).

1.3. Impacto en sostenibilidad, ético-social y de diversidad

Sobre el impacto ético ha de decirse que la protección de la privacidad se garantiza mediante el uso de registros des-identificados y la exclusión de datos personales sensibles.

Sin embargo, al basarse en encuestas telefónicas, se excluyen poblaciones vulnerables, lo que genera un sesgo en la selección de la muestra y afecta la equidad y validez del modelo (impacto de diversidad). Las poblaciones más vulnerables -como personas mayores sin acceso a tecnología, migrantes con barreras lingüísticas o individuos en situación de exclusión social- pueden quedar fuera del proceso de recogida de datos. Lo que genera un sesgo en la selección de la muestra y afecta la equidad y validez de los modelos. Perpetuándose, así, desigualdades en el acceso a la prevención y al diagnóstico.

La detección precoz de la diabetes tipo 2 tiene un impacto directo en la calidad de vida de millones de personas (impacto social). Al identificar a tiempo a los individuos con riesgo elevado, es posible aplicar cambios en el estilo de vida y tratamientos farmacológicos que retrasen o eviten la aparición de complicaciones graves (retinopatía, neuropatía, enfermedades cardiovasculares) (Knowler: 2002).

La detección precoz de la diabetes tipo 2 tiene las siguientes ventajas entre otras:

- Disminución de costes sanitarios: prevenir complicaciones reduce ingresos hospitalarios y tratamientos crónicos de alto coste.

- Mejora en pronóstico clínico: los pacientes intervenidos tempranamente presentan menores tasas de mortalidad y menor necesidad de intervenciones invasivas.
- Mejora de la actitud del paciente: una predicción personalizada facilita la adherencia a dietas, ejercicio y control médico regular.

1.4. Enfoque y método seguido

Este proyecto seguirá el proceso habitual de minería de datos para crear modelos predictivos del riesgo de diabetes tipo 2 mediante algoritmos de aprendizaje automático (algoritmos de clasificación binaria supervisada).

Las etapas clave son: Limpieza de los datos, Transformación de los datos, Reducción de dimensionamiento, Balanceo del conjunto de datos, Trato de sesgos y la Equidad en los modelos, Construcción de los modelos, Validación de los modelos. Finalmente se creará una aplicación gráfica para que mediante los modelos entrenados pueda inferir si un paciente tendrá o no diabetes.

1.5. Breve sumario de productos obtenidos

- notebook.html: notebook Jupyter contiene limpieza, imputación con Regresión logística, reducción de dimensiones hasta 30 variables o características (selección de las variables más predictivas), balanceo de clases y Mitigación de sesgos. Entrenamiento del modelo. Métricas de los modelos. Aplicación de SHAP al modelo resultante.

Cuadro 1.1: Tabla DAFO

Fortalezas Uso JupyterLab Automatización y reproducibilidad Validación metodológica	Debilidades Curva de aprendizaje en herramientas nuevas
Oportunidades Aplicación directa en salud pública Posible uso en otros campos Impacto ético-social en equidad de datos Mitigación de sesgos	Amenazas Cambios en versiones y dependencias Limitaciones en calidad de datos reales Riesgos de privacidad en datos sanitarios Conjuntos de datos con sesgos

- memoria_TFG.pdf: incluye introducción, objetivos, metodología y justificación del cambio de algoritmo.
- Guión xpt_to_csv: guion en Python con el que se ha convertido el archivo en formato XPT (SAS Transport Format) al formato CSV.
- Aplicación con interfaz gráfica.

1.6. Breve descripción de los otros capítulos de la memoria

Capítulo 2 Materiales y métodos

2.1. Fuentes de datos utilizadas

2.2. Herramientas tecnológicas

2.3. Creación del notebook

2.4. Procesamiento de datos con las diferentes etapas en las que he dividido el trabajo.

Limpiar el conjunto de datos. Transformación de los datos. Seleccionar las variables más predictivas (RFE). Balanceo con SMOTENC. Mitigación de sesgos con AIF360. Entrenar el modelo. Evaluar desempeño del modelo. SHAP.

Capítulo 3 Resultados

Reducción de variables. Balancear la variable objetivo. Mitigación de sesgos con AIF360. Explicabilidad con SHAP.

Capítulo 4 Conclusiones y trabajos futuros

Capítulo 2

Materiales y métodos

2.1. Fuentes de datos utilizadas

En este trabajo se utiliza un conjunto de datos público que está en

https://www.cdc.gov/brfss/annual_data/2014/files/LLCP2014XPT.ZIP.

Este, es una recopilación de datos de personas a quienes se han llamado por teléfono por un servicio de salud que funciona en EE.UU (Behavioral Risk Factor Surveillance System). Los datos se recopilan presentando un cuestionario llamando a teléfonos fijos y móviles.

“Es un sistema de encuestas telefónicas relacionadas con la salud que recopilan datos de todos los estados sobre los residentes de EE.UU. con respecto a sus conductas de riesgo relacionadas con la salud, condiciones de salud crónicas y uso de servicios preventivos.”(CDC, 2014)

2.2. Herramientas tecnológicas

El conjunto de datos LLCP2014.XPT está en formato nativo de la aplicación de tratamiento estadístico SAS. Este se ha convertido a formato csv

mediante un guion creado ad-hoc en Python.

Se ha empleado el lenguaje de programación Python, librerías como Pandas, scikit-learn y otras relacionadas con el aprendizaje automático, además del uso de notebooks Jupyter. La imputación de los valores faltantes del dataframe y el entrenamiento de todos los modelos se ejecutaron en CPU.

2.3. Uso combinado de Copilot y O'Reilly en el notebook

Durante el proceso de programación en el notebook con Python se emplearon dos recursos: Microsoft Copilot y la biblioteca O'Reilly. Usé Copilot como asistente interactivo y búsqueda de referencias bibliográficas, mientras que O'Reilly también proporcionó referencias bibliográficas y ejemplos prácticos de libros.

El empleo de Copilot y O'Reilly se limitó a funciones de apoyo, manteniendo siempre mi criterio para comprobar, adaptar y documentar cada sugerencia. Se prestó atención a la justificación de cada componente del código, donde la autoría y responsabilidad intelectual es del estudiante.

Es importante resaltar que el uso de Copilot para sugerir código no es directo. Comete muchos fallos por lo que hay que supervisar el código que muestra de manera iterativa.

2.4. Procesamiento de datos

Este proyecto sigue el proceso tradicional de minería de datos para crear modelos predictivos del riesgo de diabetes tipo 2 mediante algoritmos de aprendizaje automático. En la Figura 2.1 se ven los pasos generales seguidos en este TFG.

A continuación muestro las etapas que he seguido.

2.4.1. Limpiar el conjunto de datos

Limpiar el conjunto de datos del BRFSS eliminando filas y columnas innecesarias y validando la integridad de los registros (CDC, 2014).

Las columnas ["_STATE", "FMONTH", "IDATE", "IMONTH", "IDAY", "IYEAR", "DISPCODE", "SE QNO", "_PSU"] se refieren a fechas y las elimino del conjunto de datos porque no son útiles para el propósito de este TFG ya que me centro en analizar los datos de solo un año, el 2014.

DIABETE3 es la variable objetivo. En la Figura 2.3 se muestra la codificación de sus valores. Sólo nos quedamos con las filas con valores 1: Sí diabetes y 3: No diabetes que luego mapeo a Clase 1 (sí diabetes), Clase 0 (no diabetes) (Figura 2.2).

Variable objetivo (dependiente) : DIABETE3. Clase 0 (no diabetes): 348061 filas; Clase 1 (sí diabetes): 60538 filas. El conjunto de datos está muy desequilibrado. Luego lo corregiré balanceando con SMOTENC (ver apartado 2.4.5).

Elimino la variable __AGEG5YR (Figura 2.4) que son menores de 34 años. Los menores de 34 años tienen diabetes de tipo 1 y no diabetes de tipo 2

Figura 2.1: Diagrama de flujo de las etapas de creación de modelos y su evaluación



Figura 2.2: Conjunto de datos desbalanceado para DIABETE3




Figura 2.3: Valores en la variable DIABETE3 del juego de datos original

Ever told) you have diabetes

Section: 6.12 Chronic Health Conditions **Type:** Num

Column: 105 **SAS Variable Name:** DIABETE3

Prologue:

Description: (Ever told) you have diabetes (If "Yes" and respondent is female, ask "Was this only when you were pregnant?". If Respondent says pre-diabetes or borderline diabetes, use response code 4.)

Value	Value Label	Frequency	Percentage	Weighted Percentage
1	Yes	61,118	13.15	10.53
2	Yes, but female told only during pregnancy—Go to Section 07.7.1 LASTDEN3	4,207	0.91	1.01
3	No—Go to Section 07.7.1 LASTDEN3	390,827	84.11	86.78
4	No, pre-diabetes or borderline diabetes—Go to Section 07.7.1 LASTDEN3	7,668	1.65	1.48
7	Don't know/Not Sure—Go to Section 07.7.1 LASTDEN3	551	0.12	0.14
9	Refused—Go to Section 07.7.1 LASTDEN3	291	0.06	0.05
BLANK	Not asked or Missing	2		

Figura 2.4: Variable edad (_AGEG5YR)

Reported age in five-year age categories calculated variable

Calculated Variables: 8.11 Calculated Variables Type: Num

Column: 2232-2233 SAS Variable Name: _AGEG5YR

Prologue:

Description: Fourteen-level age category

Value	Value Label	Frequency	Percentage	Weighted Percentage
1	Age 18 to 24 Notes: 18 <= AGE <= 24	24,198	5.21	12.92
2	Age 25 to 29 Notes: 25 <= AGE <= 29	19,891	4.28	8.30
3	Age 30 to 34 Notes: 30 <= AGE <= 34	23,662	5.09	8.97

(Akil, 2021).

2.4.2. Transformación de los datos

División del conjunto de datos en dos particiones: entrenar/prueba

Imputación de valores faltantes (en train)

Codificación (en train). Convierte categorías en números enteros.

Escalado (en train). Convertir las variables a una escala con: media = 0, desviación estándar = 1. Para que los modelos no se vean afectados por variables con escalas distintas, aunque en mi caso solo es útil el modelado con la Regresión logística porque a los modelos creados con Random Forest, XGBoost, CatBoost no les afecta pero tampoco los perjudica.

2.4.3. Seleccionar las variables más predictivas

Seleccionar las variables más predictivas mediante el método

`sklearn.feature_selection.RFE`. RFE (Eliminación Recursiva de Características) es una técnica de selección de variables que busca identificar el subconjunto más relevante de características --es decir, variables o colum-

nas del juego de datos-- para un modelo predictivo. Pertenece a la categoría de métodos de envoltorio (wrapper)(GeeksforGeeks, 2023), porque utiliza un modelo de aprendizaje para evaluar la importancia de cada variable. RFE con Regresión Logística. Este pipeline aplica RFE usando un Regresión Logística como modelo base, para seleccionar las 50 variables más relevantes del conjunto de datos.

Su funcionamiento es el siguiente:

1. **Entrenamiento inicial.** Se ajusta el modelo con Regresión Logística usando todas las variables.
2. **Evaluación de importancia.** Se calcula la importancia de cada variable.
3. **Eliminación de variables menos relevantes.** Se eliminan las variables menos importantes.
4. **Repetición del proceso.** Se vuelve a entrenar el modelo con las variables restantes y se repite el proceso hasta alcanzar el número deseado de variables (`N_FEATURES_TO_SELECT`).

He reducido primero las dimensiones del conjunto de datos (escogiendo como parámetro 50 variables) para reducir el tiempo de cálculo del balanceado con SMOTENC.

2.4.4. Balanceo con SMOTENC

Balancear la variable objetivo mediante técnicas de over-sampling adaptadas al desequilibrio de clases (Lemaître,(n.d.)).

1. Evitamos sesgos en la selección de variables: si la clase está desbalanceada, los algoritmos de selección de características pueden favorecer las variables que explican mejor la clase mayoritaria, ignorando señales útiles para la clase minoritaria.

2. Mejor representación de patrones: al balancear antes, aseguramos que los patrones de ambas clases estén presentes en el proceso de reducción.

3. Mayor robustez del modelo final: la reducción de variables sobre un conjunto balanceado tiende a preservar variables relevantes para ambas clases, lo que mejora la generalización

He usado la técnica SMOTENC (Mukherjee, 2021) porque esta es una técnica de re-muestreo que genera ejemplos sintéticos para la clase minoritaria en datasets desbalanceados, preservando las variables categóricas. Es una versión de SMOTE adaptada para datos mixtos (numéricos + categóricos). En nuestro caso la clase minoritaria es «diabetes sí».

Aunque todas las columnas sean numéricas, algunas pueden representar categorías codificadas como números (por ejemplo, 1 : masculino, 2 : femenino) como es nuestro caso. SMOTENC permite tratar las columnas como categóricas, aunque estén codificadas numéricamente. Evita promediar valores categóricos, lo cual sería incorrecto (por ejemplo, generar un valor 1.5 entre 1 = masculino y 2 = femenino). Es muy conveniente separar explícitamente las columnas categóricas de las numéricas cuando se usa SMOTENC, incluso si todas están codificadas como números.

En el bloque de código las columnas del dataframe se separan de manera automática, mediante el uso de un umbral, en categóricas y numéricas.

(Abhishek, 2021)

2.4.5. Mitigación de sesgos con AIF360

Para la detección y mitigación de sesgos he usado AIFairness360 (Bellamy, 2018) combinándolo con el entrenamiento de modelo Regresión logística para comprobar si los sesgos se mitigan después de aplicar las correcciones al modelo (AI Fairness 360, (n.d.)).

Flujo: Transformar datos → métricas AIF360(antes) → entrenar modelo → métricas AIF360 (después).

Hay que aplicar AIF360 antes de balancear con SMOTENC para que no haya fuga de información (data leakage).

Hay que mapear la columna DIABETE3 a una etiqueta binaria para que AIF360 y los clasificadores la interpreten correctamente.

- Sí diabetes: 1 → debe convertirse en 1
- No diabetes: 3 → debe convertirse en 0

Pasos pendientes. Flujo: **Preprocesamiento → Mitigación → Reducción de características → Creación de modelos.**

La función `DISPARATE_IMPACT()` de AIF360 calcula la división entre resultado favorable del grupo no privilegiado y del grupo privilegiado.

El Disparate Impact es el ratio de resultados positivos entre grupos. El Disparate Impact ideal es el que está cercano a 1. Fórmula:

$$\text{Disparate Impact} = \frac{P(\text{resultado positivo} \mid \text{grupo protegido})}{P(\text{resultado positivo} \mid \text{grupo privilegiado})}$$

Con AIF360, al detectar `BINARYLABELDATASETMETRIC` con sesgo por

AGE__GROUP__BIN edad(usando como atributo protegido), podemos aplicar algoritmos de mitigación de sesgo que generan un nuevo conjunto de datos transformado. Ese dataset se puede exportar a CSV.

Flujo: **Baseline** → **Mitigación con Reweighing** → **Post-mitigación**

El clasificador usado en las métricas ha sido LogisticRegression y se ha mitigado el sesgo con **Reweighing** (ajuste de pesos)..

2.4.6. Entrenar el modelo

Se entrena un modelo de clasificación binaria de manera supervisada (UOC Labs). El métodos escogido para la clasificación binaria es «Regresión Logística».

En unas primeras versiones del modelo creado con el método Naive Bayes, su evaluación daba predicciones perfectas, lo cual era sospechoso. Al final descubrí que entre las características del conjunto de datos había una variable ("DIABAGE2") que predecía por sí misma el 100 % de la variable objetivo ("DIABETE3"). Descartando "DIABAGE2" del dataset las métricas de evaluación de los modelos presentaban un aspecto más realista. La variable DIABAGE2 contiene información que está directamente relacionada o derivada del objetivo (DIABETE3), lo que permitía al modelo aprender una relación artificialmente perfecta. Este fenómeno se conoce como **feature target leakage** (o fuga de información). Genera métricas engañosamente altas (como precisión perfecta, Accuracy: 1.0), que no se da en datos reales y el modelo no generaliza.

Clasificación es la tarea de predecir cuál de un conjunto de clases (categorías) a las que pertenece un ejemplo. En nuestro caso son dos clases; clasificación binaria (diabetes sí o no). {1: Sí diabetes; 0: No diabetes}

Regresión Logística

La regresión logística es uno de los modelos más adecuados y ampliamente utilizados para problemas de clasificación binaria. Se trata de un modelo de clasificación que estima la probabilidad de pertenencia a una clase. Se adapta bien a problemas binarios (sí/no). Ofrece probabilidades claras que facilitan decisiones médicas. Es interpretable: cada variable muestra su impacto en el riesgo. Tiene uso extendido en epidemiología. Maneja bien variables categóricas y continuas. Es robusta incluso con clases des balanceadas. Cuenta con amplia validación científica en estudios de diabetes tipo 2. Este modelo es adecuado cuando queremos predecir una variable Y a partir de otras variables (variables X) que formarían una combinación lineal de variables. (Martínez, 2014)

2.4.7. Cómo se entrena y valida Regresión Logística

Preparación de datos:

- Se lee el CSV con las variables seleccionadas. El csv de entrada está balanceado. Se reemplazan los valores de “No sabe/No responde” (88, 77, 99, etc.) por NaN para tratarlos como nulos. Se definen las variables explicativas (FEATURES) y la variable objetivo (TARGET). Balanceo de clases. Se usa `train_test_split` con `stratify=y` para mantener la proporción de clases en train y test. Pipeline: preprocesamiento

+ modelo de clasificación. Imputación: rellena valores nulos con `SimpleImputer(strategy="most_frequent")`. Codificación: convierte variables categóricas en variables binarias con `OneHotEncoder`.

Definición del modelo:

- Regresión logística: se entrena con `class_weight="balanced"` para compensar posibles desbalances, utilizando el solver `liblinear` (`solver="liblinear"`) rápido y consistente para datos grandes y variables categóricas.

Entrenamiento:

- Todo se integra en un pipeline para que el preprocesamiento y el modelo se apliquen juntos. Validación cruzada estratificada (5 splits). Se utiliza `StratifiedKFold` para dividir los datos en 5 particiones manteniendo la proporción de clases. Se entrena el modelo en el conjunto de entrenamiento. Se predice en el conjunto de validación.

Evaluación del modelo:

- Se calculan métricas: Accuracy, Precision, Recall, F1 y ROC-AUC.

2.4.8. Evaluar el desempeño de los modelos

Evaluar el desempeño de los modelos con métricas de precisión, sensibilidad, especificidad y AUC-ROC (Saito y Rehmsmeier, 2015).

El F1-score es una forma práctica de combinar precisión y sensibilidad en una sola métrica, especialmente útil cuando se necesita comparar dos clasificadores.

Cuadro 2.1: Matriz de confusión

	Predicción: No diabetes	Predicción: Sí diabetes
Real: No diabetes	TN	FP
Real: Sí diabetes	FN	TP

En diagnóstico médico aunque el dataset esté balanceado, el costo de los errores (como falsos negativos) puede seguir siendo alto. Por eso, en medicina se suele priorizar recall (sensibilidad) o F1-score, no por el balance del dataset, sino por la gravedad de los errores.

Interesa maximizar recall de un algoritmo si el objetivo es identificar todos los casos positivos relevantes. Prioriza el valor F1-score cuando los datos presentan un desequilibrio significativo entre clases positivas y negativas, como ocurre en diagnósticos médicos, donde los falsos negativos no son deseables.

{1: Sí diabetes; 0: No diabetes}

- TN (True Negative)
- TP (True Positive)
- FP (False Positive)
- FN (False Negative)

El total de cada fila muestra todos los positivos pronosticados (TP + FP) y todos los negativos pronosticados (FN + TN), independientemente de la validez. En cambio, el total de cada columna muestra todos los verdaderos positivos (TP + FN) y todos los verdaderos negativos (FP + TN), independientemente de la clasificación del modelo. Ver Cuadro 3.7. (Google Developers, 2025)

Métricas derivadas. A partir de esta matriz podemos calcular:

- $\text{Accuracy} = (\text{TP} + \text{TN}) / \text{Total}$

- $\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$
- $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$
- $\text{F1-score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$

Accuracy (exactitud)

Cuando un tipo de error (FN o FP) es más costoso que el otro - como en diagnóstico médico, donde un falso negativo (FN) puede significar no detectar una enfermedad- que es nuestro caso, no basta con optimizar la accuracy, porque esta métrica trata todos los errores por igual. Es mejor optimizar para una de las otras métricas (F1-score, Precision, Recall). Recall (sensibilidad): mide cuántos casos positivos reales se detectan. Útil cuando los falsos negativos son más peligrosos, como en la detección de diabetes, así que optimizar el recall es lo más prudente. Esto puede implicar usar un umbral más bajo para que el modelo sea más sensible, aunque aumenten los falsos positivos.

Recall (sensibilidad)

Mide cuántos casos positivos reales se detectan. Útil cuando los falsos negativos son más peligrosos, como en la detección de diabetes, así que optimizar el recall es lo más prudente. Esto puede implicar usar un umbral más bajo para que el modelo sea más sensible, aunque aumenten los falsos positivos.

2.4.9. SHAP

SHAP. Indica la aportación de cada característica al resultado de la predicción del modelo. SHAP (SHapley Additive exPlanations) es un método

de interpretación de modelos de aprendizaje automático que permite evaluar cómo cada variable influye en las predicciones, incluso en modelos complejos o poco transparentes. Calcula la contribución marginal de cada característica (feature) para entender su efecto positivo o negativo en el resultado. En contextos como el diagnóstico médico, esta explicabilidad es muy importante para generar confianza en profesionales y pacientes. (Peng, 2024) A cada característica se le asigna un valor de importancia que representa su contribución al resultado del modelo. Con los valores SHAP y conseguimos dar interpretabilidad a los modelos de machine learning. Tener modelos precisos es necesario, pero también es importante saber interpretarlos y que sean transparentes. Ser capaz de explicar por qué un modelo hizo una predicción concreta ayuda a tratar posibles sesgos, identificar problemas con los datos y justificar las decisiones del modelo. (Awan, 2024)

La falta de interpretabilidad de los modelos de ML para predecir en enfermedades crónicas como la diabetes ha limitado su adopción por parte del mundo sanitario. Para corregirlo se ha creado SHAP.

Con SHAP se dibuja un diagrama donde se muestra la influencia de cada factor en la predicción del modelo. Cita: «Al cuantificar la contribución de cada característica, SHAP permite a los médicos, profesionales de la salud pública o usuarios finales rastrear el razonamiento detrás de una clasificación de alto o bajo riesgo.» (Allani, 2025)

2.5. Análisis de riesgos

Desbalance de clases. El BRFSS incluye variables de salud con distribuciones desiguales, lo que puede inducir a los modelos a favorecer la clase mayoritaria y generar métricas engañosas (alta precisión global pero baja sensibilidad en la clase minoritaria). Aunque la diabetes tipo 2 está bien representada, la variable objetivo “¿Tiene diabetes?”, presenta un cierto desbalance: predominan los registros de personas sin diabetes frente a los casos positivos. Este sesgo puede reducir el rendimiento en métricas críticas como recall y F1-score, afectando la capacidad de identificar correctamente a individuos con diabetes, algo prioritario en salud pública (Chawla, 2002). Para mitigar el desbalance se aplicó over-sampling en el notebook de la clase minoritaria con SMOTENC y se utilizaron métricas robustas. Se evitó el uso exclusivo de Accuracy y se priorizaron métricas como F1-score, ROC-AUC y curvas de precisión-recall, que reflejan mejor el rendimiento en la clase minoritaria.

Hay que evitar el sobreajuste (overfitting) que ha aparecido debido al feature target leakage (o fuga de información) al entrenar los modelos. Genera métricas engañosamente altas (como precisión perfecta, Accuracy: 1.0), que no se da en datos reales y el modelo no generaliza. (Ver apartado 2.4)

Limitaciones del BRFSS. El BRFSS es una encuesta poblacional basada en datos auto informados, lo que introduce sesgos de memoria, percepción e información. Además, algunas variables presentan categorías poco representadas o distribuciones muy desiguales. Estas limitaciones restringen la precisión absoluta del modelo y su capacidad de reflejar la realidad clí-

nica. Para mitigar este riesgo se aplicaron estrategias de preprocesamiento (imputación de valores faltantes, codificación robusta de variables categóricas), una selección atenta de variables y una interpretación cuidadosa de los resultados, de manera que el modelo refleje patrones poblacionales y no diagnósticos individuales.

Problemas de generalización. Un modelo entrenado en datos del BRFSS puede no generalizar bien a otras poblaciones con características socioeconómicas, culturales o sanitarias diferentes. Esto limita su aplicabilidad directa fuera del ámbito geográfico de la encuesta. Para mitigar este riesgo se recomienda realizar evaluaciones externas en otros conjuntos de datos o datos clínicos, utilizar métricas robustas como ROC-AUC y curvas de precisión-recall para evaluar la capacidad de discriminación, y considerar su interpretación, considerando las predicciones de los modelos como una manera de examinar factores de riesgo más que como un predictor definitivo.

Capítulo 3

Resultados

3.1. Procesamiento de datos


3.1.1. Reducción de variables

Se escogen las variables más predictivas. Las variables más explicativas calculadas usando RFE se muestran en Figura 3.1, Cuadro 3.1 y 3.2.

En el cuadro 3.1 solo he recogido las variables seguras, sin fuga de datos. Variables seguras son aquellas que no revelan directa ni indirectamente el valor de la variable objetivo (diabetes) y no son consecuencia de tener diabetes. Variables seguras son aquellas variables que no contienen información clínica, diagnóstica o derivada del propio hecho de tener diabetes.

Cuadro 3.1: Las variables más explicativas según RFE
'_STSTR', 'WTKG3', 'CTELENUM', 'ASBIDRNK', 'ASBIRDUC', 'WTCHSALT', 'CSRVSUM', 'CSRVPA', 'SCNTMEL1', 'SCNTPAID', 'SCNTLPAD', 'SCNTVOT1', 'CTELNUM1', '_RFHLTH', '_RACEG21', '_A

Figura 3.1: Gráfica con las variables más explicativas y su grado de importancia



Variable	Descripción
_STSTR	Estrato de murstreo.
WTKG3	Peso en kilogramos.
CTELENUM	Número de teléfonos en el hogar.
ASBIDRNK	Consumo de bebidas alcohólicas.
ASBIRDUC	Consumo de bebidas dietéticas.
WTCHSALT	Evita la sal en las comidas.
CSRVSUM	Realiza servicio comunitario.
CSRVPAIN	Realiza servicio para personas con dolor.
SCNTMEL1	Frecuencia de sentirse solo.
SCNTPAID	Frecuencia de estrés por problemas monetarios.
SCNTLPAD	Frecuencia de extresarse por salir tarde.
SCNTVOT1	Participación en votaciones.
CTELNUM1	Uso del teléfono celular.
_RFHLTH	Estado general de salud percibida.
RACEG21	Categoría racial / étnica.
_AGE_G	Grupo de edad.
_BMI5CAT	Categoría de IMC (Índice de Masa Corporal).

Figura 3.2:

Cuadro 3.2: Sesgo según edad

<code>df['age_group'].map({'jóvenes': 0, 'mayores': 1})</code>
Disparate impact (antes): 0.37542245244029515
Disparate impact (después): 0.9999999999999998

3.1.2. Balancear la variable objetivo

Una manera de balancear la variable objetivo es mediante técnicas de oversampling con SMOTENC (Figura 3.2). Se crean valores sintéticos de la clase minoritaria (diabetes sí; clase 1). Las dos clases quedan equilibradas en el número de casos en el nuevo conjunto de datos.

3.1.3. Mitigación de sesgos con AIF360

La función `DISPARATE_IMPACT()` de AIF360 calcula la división entre resultado favorable del grupo no privilegiado y del grupo privilegiado.

Antes de la mitigación (para jóvenes y mayores):

- **Disparate Impact** de 0.375 significa que: el grupo no privilegiado (jóvenes) recibe predicciones positivas (p.ej., “diabetes = 1”) solo el 37.5 % de las veces que las recibe el grupo privilegiado (mayores). Esto indica una fuerte desventaja para los jóvenes.

Después de la mitigación:

- **Disparate Impact** de 0.9999999999999998 que en la práctica es 1.0. Significa que la probabilidad de recibir una predicción positiva es idéntica entre jóvenes y mayores, esto es, el modelo ya no favorece a ningún

Cuadro 3.3: Interpretación métrica Disparate Impact de AIF360

Valor	Interpretación
cercano a 1	equidad
< 0.8	posible discriminación contra el grupo no privilegiado
> 1.25	posible discriminación contra el grupo privilegiado.

grupo. El preprocesamiento con Reweighing ha equilibrado completamente la distribución de predicciones entre ambos grupos. (Cuadro 3.2)

El Disparate Impact es el ratio de resultados positivos entre grupos. El Disparate Impact ideal es el que está cercano a 1. Fórmula:

$$\text{Disparate Impact} = \frac{P(\text{resultado positivo} \mid \text{grupo protegido})}{P(\text{resultado positivo} \mid \text{grupo privilegiado})}$$

Con AIF360, al detectar BINARYLABELDATASETMETRIC con sesgo por AGE_GROUP_BIN edad(usando como atributo protegido), podemos aplicar algoritmos de mitigación de sesgo que generan un nuevo conjunto de datos transformado. Ese dataset se puede exportar a CSV.


Flujo: **Baseline** → **Mitigación con Reweighing** → **Post-mitigación**

El clasificador usado en las métricas ha sido LogisticRegression.

La mitigación con **Reweighing** (ajuste de pesos) ha mejorado mucho la equidad del modelo, aunque el Disparate Impact (0.6) todavía está por debajo del umbral de 0.8, por lo que hay margen de mejora. En la Figura 3.1. se combinan **fairness** y **rendimiento** en una misma tabla comparativa, antes y después de la mitigación con Reweighing.

El Cuadro 3.4 y la Figura 3.2 muestran que la mitigación con AIF360

Figura 3.3: Antes y después de la mitigación



mejora la equidad de forma clara y mejora ligeramente el rendimiento predictivo. El modelo se vuelve más justo sin sacrificar calidad. La barra, cuanto más cerca esté del umbral 0.8 más justo es. La mitigación no perjudica al modelo; incluso lo mejora ligeramente. El modelo pasa de mostrar fuerte sesgo contra jóvenes a un comportamiento mucho más equilibrado.

3.1.4. Modelo de Regresión Logística

Valores obtenidos para el modelo de regresión logística:

Promedios:

Fold 3.000000

Accuracy 0.705914

Precision 0.697887

Recall 0.726200

F1 0.711761

ROC_AUC 0.781355

Estos valores muestran que el modelo de regresión logística está funcio-

Métrica	Valor	Interpretación
Fold	3	Promedio sobre 3 validaciones cruzadas: estabilidad moderada.
Accuracy	0.706	El modelo acierta en ~70 % de los casos; correcto para datos reales y desbalanceados.
Precision	0.698	De los casos predichos como "diabetes", ~70 % son verdaderos positivos.
Recall	0.726	El modelo detecta ~73 % de los casos reales de diabetes; buen nivel de sensibilidad para cribado.
F1	0.712	Equilibrio entre precisión y recall; indica rendimiento balanceado.
ROC_AUC	0.781	Capacidad discriminativa buena: el modelo separa correctamente positivos y negativos en ~78 % de las veces.

Cuadro 3.4:

nando de forma sólida y equilibrada para un problema de clasificación binaria como la predicción de diabetes en BRFSS.

Interpretación de estos valores:

Conclusión técnica:


El modelo tiene rendimiento adecuado para un cribado (screening) poblacional, con buena sensibilidad (recall) y aceptable precisión. En salud pública, ese equilibrio es preferible a maximizar accuracy.

3.1.5. Explicabilidad con SHAP

Variables de entrada y qué explican.

El modelo de regresión logística capta variables clínicas, factores como el acceso a servicios sanitarios y la auto percepción de salud. Se ha logrado identificar un conjunto de características informativas, robustas y socialmente

Figura 3.4: Diagrama SHAP con Regresión Logística



relevantes que sirven tanto para la prevención como para diseñar políticas públicas.

En el diagrama SHAP (Figura 3.4) cada barra horizontal indica cuánto contribuye una variable, en promedio, a las predicciones del modelo. El eje X muestra la magnitud media de los valores SHAP (sin signo), que refleja la influencia global de cada variable. Las variables están ordenadas de mayor a menor importancia. Valores SHAP altos: la variable tiene un fuerte impacto en la predicción (positiva o negativa). Valores SHAP bajos: la variable tiene poco efecto en la decisión del modelo.

Capítulo 4

Conclusiones y trabajos futuros

Un principio rector en medicina es que en los diagnósticos médicos interesa identificar todos los casos positivos relevantes donde los falsos negativos no son deseables. Es mejor tener un exceso de falsos positivos que serían evaluados posteriormente para confirmarlo.

Al modelo de Regesión Logística se le aplica SHAP, método para explicar las predicciones del mismo. Como conclusión, el riesgo de diabetes depende tanto de parámetros clínicos como de hábitos de vida, acceso a la atención médica y factores demográficos.

En un principio tenía previsto usar la GPU para entrenar los modelos creyendo que el crearlos sería costoso en tiempo de ejecución pero he comprobado que se crean en segundos o pocos minutos con la CPU. Más importante es la cantidad de RAM disponible. Por ejemplo, aplicando RFE mediante Random Forest usaba una gran cantidad de RAM, más de 32 GB, por lo que obté por usar el algoritmo de Regresión Logística, que usaba 9 GB. He usado sólo una CPU multinúcleo para entrenar. Crear el código es más sencillo que

usando GPU con CUDA.

En el conjunto de datos originales había sesgo por edad. Se han mitigado el sesgo por edad y actualizado el dataset en consecuencia. La clase no privilegiada eran los jóvenes.

Aparición no prevista de *feature data leakage* en la creación de los primeros modelos. Una vez corregida he podido entrenar los modelos con métricas realistas (no con Accuracy del 1.0).

Como líneas de trabajo futuro que no he explorado en este trabajo y han quedado pendientes: crear modelos con otros algoritmos y compararlos para elegir aquel con mayor rendimiento. Hay que tener en cuenta que para diferentes conjuntos de datos los algoritmos con mejor rendimiento cambian de caso en caso.

Capítulo 5

Glosario

AUC: Área bajo la curva

BRFSS: Behavioral Risk Factor Surveillance System (Sistema de Vigilancia de Factores de Riesgo Conductuales)

CDC: Los Centers for Disease Control and Prevention.

CSV: Comma Separated Values

DAFO: Debilidades, Amenazas, Fortalezas y Oportunidades.

DM2: Diabetes Mellitus Tipo 2.

GPU: unidad de procesamiento gráfico (del inglés graphics processing unit).

GUI: Interfaz gráfica de usuario.

RFE: Recursive Feature Elimination de Scikit-learn.

ROC: Es una curva cuya forma indica la capacidad de un modelo de clasificación binaria para separar las clases positivas de las negativas.

SAS: Statistical Analysis System. Software especializado en análisis estadístico, gestión de datos y minería de datos.

SHAP: SHapley Additive exPlanations. Indica la aportación de cada característica al resultado de la predicción del modelo

SMOTE: Synthetic Minority Over-sampling Technique.

SMOTENC: Synthetic Minority Oversampling Technique for Nominal and Continuous

T2DM: Type 2 Diabetes Mellitus.

Capítulo 6

Bibliografía

Bibliografía

- [1] Abhishek, K., & Abdelaziz, M. (2023). Machine learning for imbalanced data. Packt Publishing. Recuperado de <https://learning.oreilly.com/...>
- [2] AI Fairness 360 Development Team. (n.d.). AI Fairness 360 documentation (aif360 0.6.1). Read the Docs. <https://aif360.readthedocs.io/en/stable/index.html>
- [3] Allani, U. (2025). Interactive diabetes risk prediction using explainable machine learning. arXiv:2505.05683. <https://arxiv.org/pdf/2505.05683>
- [4] Akil, A. A., Alsulaiman, M., & Alghamdi, A. A. (2021). Diagnosis and treatment of type 1 diabetes. Journal of Translational Medicine, 19(1), 1-15. <https://pubmed.ncbi.nlm.nih.gov/33794915/>
- [5] Amokun, R., Arowolo, T., & Eke, J. (2025). Comparative analysis of ML algorithms for heart disease prediction. EasyChair Preprint No. 15706. <https://easychair.org/...>
- [6] Ashisha, G. R., et al. (2024). Random oversampling-based diabetes classification. International Journal of Computational Intelligence Systems, 17(270). doi:10.1007/s44196-024-00678-3

- [7] Awan, A. A. (2024). Introduccion a los valores SHAP. DataCamp.
<https://www.datacamp.com/...>
- [8] Bellamy, R. K. E., et al. (2018). AI fairness 360. arXiv:1810.01943.
[doi:10.48550/arXiv.1810.01943](https://doi.org/10.48550/arXiv.1810.01943)
- [9] Bentejac, C., Csorgo, A., & Martinez-Munoz, G. (2019). A Comparative Analysis of XGBoost. <https://arxiv.org/abs/1911.01914>
- [10] CDC. (2014). Behavioral risk factor surveillance system survey questionnaire.
- [11] Chawla, N. V., et al. (2002). SMOTE. Journal of Artificial Intelligence Research, 16, 321-357. [doi:10.1613/jair.953](https://doi.org/10.1613/jair.953)
- [12] Chen, F., et al. (2025). Type 2 diabetes and asthma incidence. BMC Public Health, 25, 166. [doi:10.1186/s12889-024-21266-2](https://doi.org/10.1186/s12889-024-21266-2)
- [13] Chowdhury, M. M., et al. (2024). ML algorithms and augmentation for diabetes diagnosis. Healthcare Analytics, 5, 100297. [doi:10.1016/j.health.2023.100297](https://doi.org/10.1016/j.health.2023.100297)
- [14] GeeksforGeeks. (2023). Wrapper Methods - Feature Selection. <https://www.geeksforgeeks.org/...>
- [15] Geron, A. (2023). Hands-on machine learning with Scikit-Learn and PyTorch. <https://learning.oreilly.com/...>
- [16] Google Developers. (2025). Umbrales y matriz de confusion. <https://developers.google.com/...>

- [17] Google Developers. (s.f.). ROC and AUC. <https://developers.google.com/...>
- [18] Hancock, J. T., & Khoshgoftaar, T. M. (2020). CatBoost for Big Data. <https://www.researchsquare.com/...>
- [19] Knowler, W. C., et al. (2002). Reduction in the incidence of type 2 diabetes. NEJM, 346(6), 393-403. <https://www.nejm.org/...>
- [20] Lemaitre, G., et al. (2017). Imbalanced-learn. Journal of Machine Learning Research, 18(17), 1-5. <https://jmlr.org/...>
- [21] Martinez-Gonzalez, M. A., et al. (2014). Bioestadística amigable. Elsevier España.
- [22] Mitigation Strategies. International Journal for Research Publication and Seminar, 15, 36-49. <https://www.researchgate.net/...>
- [23] Moccia, C., et al. (2024). Machine learning in causal inference for epidemiology. European Journal of Epidemiology, 39(1), 1-14. [doi:10.1007/s10654-024-01173-x](https://doi.org/10.1007/s10654-024-01173-x)
- [24] Mukherjee, M., & Khushi, M. (2021). SMOTE-ENC. Applied System Innovation, 4(1), 18. [doi:10.3390/asi4010018](https://doi.org/10.3390/asi4010018)
- [25] Li, W., Peng, Y., & Peng, K. (2024). Diabetes prediction model based on GA-XGBoost. PLoS ONE, 19(9), e0311222. [doi:10.1371/journal.pone.0311222](https://doi.org/10.1371/journal.pone.0311222)
- [26] Ramirez Jimenez, O. (2022). Python a fondo. Marcombo.

- [27] Saito, T., & Rehmsmeier, M. (2015). Precision-recall plot vs ROC. PLOS ONE, 10(3), e0118432. [doi:10.1371/journal.pone.0118432](https://doi.org/10.1371/journal.pone.0118432)
- [28] Scikit-learn. (s.f.). Feature selection. <https://scikit-learn.org/...>
- [29] Scikit-learn. (s.f.). SelectFromModel. <https://scikit-learn.org/...>
- [30] UOC Labs. (n.d.). Supervised learning classification. <https://gitlab.uoclabs.uoc.es/...>

Capítulo 7

Anexos

Conversión del conjunto de datos LLCP2014.XPT

El conjunto de datos LLCP2014.XPT se encuentra originalmente en formato XPT (SAS Transport Format), utilizado por la aplicación estadística SAS para el intercambio estructurado de datos entre plataformas. Este formato, aunque normalizado, no es directamente compatible con entornos de análisis en Python, por lo que fue necesario realizar una conversión previa. Para ello, se desarrolló un guion en Python que permite transformar el archivo .XPT al formato CSV, facilitando su posterior tratamiento en bibliotecas como pandas, scikit-learn. Este proceso garantiza la integridad de los datos y permite su integración en flujos de trabajo reproducibles y automatizados.

Aplicación de predicción con interfaz gráfica

He creado una aplicación con Python y Tkinter (Figura 7.1) como ejemplo de uso del modelo entrenado y preparado para predecir si a partir de los datos cargados de una fila del dataset csv el individuo tiene diabetes o no. Tkinter es un framework para crear aplicaciones con interfaz gráfica que usa el toolkit

Figura 7.1: Aplicación de predicción con interfaz gráfica

The screenshot shows a web application window titled "Predicción de Diabetes (Regresión Logística)". It contains a list of input variables and their corresponding values in dropdown menus:

Variable	Value
_RFHLTH	1 - Fair
_AGE_G	4 - 55-64
_BMI5CAT	2 - Overweight
_RACEG21	0 - White
WTCHSALT	1 - Yes
ASBIRDUC	1 - Yes
CTELNUM1	0 - None
CTELENUM	0 - No
SCNTMEL1	1 - 1-7 days

Below the input fields, the results are displayed:

Resultado: No diabetes
Prob. diabetes No: 0.526
Prob. diabetes Sí: 0.474

A "Predecir" button is located at the bottom left of the form.

Tcl/Tk. Ambos, framework y toolkit, están incluidos por defecto en Python. (Ramírez, 2022)

Instrucciones de instalación de la aplicación

La aplicación Python está creada en un PC1 con sistema operativo Linux/Ubuntu 22.04. La versión de Python de este PC1 es 3.9.18. Para que este programa funcione en otra versión de sistema operativo lo conveniente es crear en el PC2 un entorno virtual Python nuevo. Hay que Instalar la versión de Python 3.9.18. Para ello hay que descargar previamente la versión de Python 3.9.18 y compilarla (en el PC2).

Una vez instalada la nueva versión de Python, con el fichero requirements.txt adjunto se instalan las librerías necesarias. Con pip install se descargan dentro del entorno virtual, sin afectar al sistema global del PC2.

PC1:

```
source app_diabetes_env/bin/activate  
(app_diabetes_env) alex@ryzen5:~/AppGUI_0.9$ pip freeze >  
requirements.txt
```

PC2:

```
python3 -m venv app_diabetes_env  
source app_diabetes_env/bin/activate  
pip install -r requirements.txt
```

- El sistema operativo del PC2 podrá seguir usando su versión de Python aunque no sea compatible con la aplicación.
- El entorno virtual empleará Python 3.9.18 y tendrá las mismas librerías que en PC1.
- Así se puede trabajar con ambos sin conflictos.